

# Lual ETEX-basierter Prototyp zum Erstellen barrierefreier Dokumente

Axel Strübing axel.struebing@le-tex.de

12. März 2024



### Gliederung

- 1. Motivation
- 2. Anforderungen
- 3. Das Itpdfa-Paket
- 4. LualATFX, Dvips & Distiller
- 5. Ergebnis
- 6. Status
- 7. Appendix



### Warum barriefreie Dokumente ...

- Zugänglichkeit zu Informationen
- ► Barrierefreien-Informationstechnik-Verordnung (BITV)
- ► European Accessibility Act (EAA) & BFSG
- ► PDF-UA & WCAG



### Warum barriefreie Dokumente ...

- Zugänglichkeit zu Informationen
- ► Barrierefreien-Informationstechnik-Verordnung (BITV)
- European Accessibility Act (EAA) & BFSG
- ► PDF-UA & WCAG

und warum ich?



### Warum barriefreie Dokumente ...

- Zugänglichkeit zu Informationen
- Barrierefreien-Informationstechnik-Verordnung (BITV)
- European Accessibility Act (EAA) & BFSG
- PDF-UA & WCAG

#### und warum ich?

- nutze TEX (und Linux) seit den 90er-Jahren
- bin Verfechter freier Software
- TEX = resourcenschonend, automatisierbar, Verfügbarkeit
- Programmieren als Hobby
- für meinen Arbeitgeber ;-)



- Sprache, XMP-Metadaten, Strukturbaum, OutputIntent (Farbprofil) im Catalogobjekt des PDF
  - Catalog

```
/MarkInfo<</Marked true>> /StructTreeRoot 176 0 R
/OutputIntents [174 0 R] /Metadata 175 0 R /Lang(De)
/ViewerPreferences<</DisplayDocTitle>>
```

- mittels /OutputIntent muss bei Gebrauch von Farbe ein Farbprofil eingebettet werden (z.B. sRGB IEC61966-2.1)
- als XMP(XML) müssen Metadaten u.a. die Konformität zur enthaltenden Version des PDF-Standards ausweisen



- Sprache, XMP-Metadaten, Strukturbaum, OutputIntent (Farbprofil) im Catalogobjekt des PDF
  - Catalog

```
/MarkInfo<</Marked true>> /StructTreeRoot 176 0 R
/OutputIntents [174 0 R] /Metadata 175 0 R /Lang(De)
/ViewerPreferences<</DisplayDocTitle>>
```

- mittels /OutputIntent muss bei Gebrauch von Farbe ein Farbprofil eingebettet werden (z.B. sRGB IEC61966-2.1)
- als XMP(XML) müssen Metadaten u.a. die Konformität zur enthaltenden Version des PDF-Standards ausweisen
- /StructTreeRoot verweist auf den Wurzelknoten des Strukturbaumes, enthält /RoleMap und als Kindelemente /StructElem



- 2. Für ein barrierefreies PDF müssen zusätzlich mindestens noch folgende semantischen Auszeichnungen gewährleistet werden
  - Einbettung von Fonts mit korrekten ToUnicode-Mappings (Textextraktion, Screen-Reader)
  - Worte durch Leerzeichen getrennt sein
  - automatische Trennstellen markiert sein



- 2. Für ein barrierefreies PDF müssen zusätzlich mindestens noch folgende semantischen Auszeichnungen gewährleistet werden
  - Einbettung von Fonts mit korrekten ToUnicode-Mappings (Textextraktion, Screen-Reader)
  - Worte durch Leerzeichen getrennt sein
  - automatische Trennstellen markiert sein
  - komplette Markierung des Contents in der Seitenbeschreibung

```
/H <</MCID 0>> BDC
BT
/F26 20.66252 Tf
1 0 0 1 158.087 504.334 Tm [(Hallo)]TJ
ET
EMC
```

• Kategorisierung in Artefakte, Layoutelemente, Content und den Typ



# semantische Anforderungen

Zuweisung von Seiteninhalt zu einer Liste von Standardtypen (Article, H,  $P \dots$ )

Für viele Inhalte ist eine alternative Repräsentation (Alt, ActualText, Title, Contents etc.) gefordert!

Inhalte in einer korrekten/plausiblen Lesereihenfolge taggen.

Farben und Kontraste müssen deutlich erkennbar sein.



# semantische Anforderungen

#### Probleme:

- ► Wie werden Formeln alternativ dargestellt?
- ▶ Redaktionelle, nicht automatisiserbare Aufgaben.
- ▶ Methoden zur Integration externer Quellen erforderlich.



# Das Hauptproblem

### T<sub>E</sub>X-Input

Aus dem Input

\chapter{Preface} Here comes \ldots

werden in TEX's "Verdauungstrakt" zuerst expandierbare Tokens, dann nicht weiter expandierbare Tokens und letztendlich Boxen/Knotenlisten in der Outputroutine.

Dabei geht jegliche semantische Information über die originäre Bedeutung verloren (chapter, table usw.)!

### Aufgabe

Transport der semantischen Eigenschaften bis in die Outputroutine (seitenweise Auszeichnung erforderlich).



### Das Hauptproblem

```
Callback: post linebreak filter
-GLUE subtype: baselineskip, width: 4.95pt
HLIST subtype: line, width: 345pt, depth: 0.11pt, height: 7.05pt
 ∟head:
    -LOCAL_PAR
    -HLIST subtype: indent, width: 15pt
    GLYPH subtype: 256, char: P, width: 6.81pt, height: 6.83pt
    GLYPH subtype: 256, char: r, width: 3.92pt, height: 4.42pt
    -GLYPH subtype: 256, char: e, width: 4.44pt, height: 4.48pt, depth: 0.11pt
    GLYPH subtype: 256, char: f, width: 3.06pt, height: 7.05pt
    -DISC subtype: regular, penalty: 50
     ∟pre:
        GLYPH subtype: 256, char: -, width: 3.33pt, height: 2.45pt
    HGLYPH subtype: 256, char: a, width: 5pt, height: 4,48pt, depth: 0.11pt
    GLYPH subtype: 256, char: c, width: 4.44pt, height: 4.48pt, depth: 0.11pt
    GLYPH subtype: 256, char: e, width: 4.44pt, height: 4.48pt, depth: 0.11pt
    GLUE subtype: spaceskip, width: 3.33pt, stretch: 1.66pt, shrink: 1.11pt
    GLYPH subtype: 256, char: H. width: 7.5pt, height: 6.83pt
    GLYPH subtype: 256, char: e, width: 4.44pt, height: 4.48pt, depth: 0.11pt
    GLYPH subtype: 256, char: r, width: 3.92pt, height: 4.42pt
    GLYPH subtype: 256, char: e, width: 4.44pt, height: 4.48pt, depth: 0.11pt
    GLUE subtype: spaceskip, width: 3.33pt, stretch: 1.66pt, shrink: 1.11pt
    HGLYPH subtype: 256, char: c. width: 4.44pt, height: 4.48pt, depth: 0.11pt
    GLYPH subtype: 256, char: o, width: 5pt, height: 4.48pt, depth: 0.11pt
    GLYPH subtype: 256, char: m, width: 8.33pt, height: 4.42pt
    GLYPH subtype: 256, char: e, width: 4.44pt, height: 4.48pt, depth: 0.11pt
    HGLYPH subtype: 256, char: s. width: 3.94pt, height: 4.48pt, depth: 0.11pt
    GLUE subtype: spaceskip, width: 3.33pt, stretch: 1.66pt, shrink: 1.11pt
    GLYPH subtype: 256, char: ..., width: 6.7pt, height: 1.06pt
    -PENALTY subtype: linepenalty, penalty: 10000
    -GLUE subtype: parfillskip, stretch: +1fil
    GLUE subtype: rightskip
```



# zum Hauptproblem

### Attribute als Lösungsansatz

Mit LuaTEX wurden sogenannte Attribute eingeführt.

Diese gehorchen den von TEX bekannten Regeln der Gruppierung, werden bisher wenig genutzt und haben einen großen Wertebereich von  $2^{32}$ .

Im Itpdfa-Code werden zwei neue Attribute alloziert:

parentattr: dient als Strukturzähler typeattr: dient zur Typmarkierung



### zum Hauptproblem

Damit erhält jeder Knoten die Information zu seinem Elternelement (parentattr) sowie seinen ursprünglichen, semantischem Typ (typeattr).

Die zu lösenden Aufgaben sind nun:

- \structStart, \structEnd einzufügen
   Anpassung von TEX-Makros und -Styles
- Analyse der umbrochenen Seite und Zuordnung allen Inhalts zu den bereits existierenden Strukturelelementen
  - => \ShipoutBox aus AtBegshi-Paket
- 3. eine Menge "Housekeeping"
- 4. am Ende des Dokumentes generieren aller nötiger PDF-Strukturen (oder der Vehikel dafür)



#### **Features**

Der Code von Itpdfa nutzt diesen Ansatz, definiert ein schlankes TEX-Paket und springt so direkt wie möglich nach Lua. Es wurden folgende Fähigkeiten umgesetzt:

- DVI oder PDF-Backend wählbar
- globale Sprachangabe, Konfiguration der XMP-Daten, Angabe des Farbprofils
- Anpassung des ToUnicode-Mappings (DVI)
- automatische Markierung von Wortzwischenräumen als Leerzeichen
- ebenso Trennstellen



#### Features

- visual debug erkannter Leerzeichen und Trennstellen
- automatisches Schließen von Sections konfigurierbar
- verschieben, löschen und ignorieren von Strukturen
- "Autotagging" durch Hooks in \begin und \end Makros
- Anpassungen an grundlegenden Lagender Lagend



### Beispiel

```
\documentclass[12pt,a4paper,twoside]{book}
%% want dvi output
\outputmode=0
\RequirePackage{makeidx}
\RequirePackage{tabularx}
\RequirePackage{fongtable}
\RequirePackage{multirow}
\RequirePackage{graphicx}
\RequirePackage[table]{xcolor}
\RequirePackage[multicol]
\RequirePackage[distps,pdflang=De,dospaces,debug,nodetree]{ltpdfa}
%headnums,showspaces,nodetree
\RequirePackage{lmodern}
\renewcommand\encodingdefault{OT1}
\toUnicode{LMMathSymbols,LMMathExtension}
```



#### L Funktionsweise

```
├GLUE width: 23pt, attr: 4=114 5=27
 -VLIST width: 390pt, height: 653.87pt, shift: 52pt, attr: 4=114 5=27
   -VLIST width: 390pt, height: 12pt, attr: 4=114 5=27
     head:
       ⊢GLUE stretch: +1fil, attr: 4=114 5=27
       HLIST subtype: box, width: 390pt, depth: 0.25pt, height: 8.45pt, attr: 4=114 5=27
            -WHATSIT subtype: pdf colorstack, data: 0 g 0 G, attr: 4=114 5=27
            HLIST subtype: box, width: 390pt, depth: 0.25pt, height: 8.45pt, attr: 4=114 5=27
             ∟head:
               HHATSIT subtype: pdf literal, mode: 1, data: /Artifact <</Type/Pagination/Subtype/Header>> BDC, attr: 4=113
               GLYPH subtype: 256, char: i, width: 3.26pt, height: 7.84pt, attr: 4=113 5=30
               -GLYPH subtype: 256, char: v, width: 6.2pt, height: 5.17pt, depth: 0.12pt, attr: 4=113 5=30
               -GLYPH char: , width: 3.33pt, attr: 4=113 5=30
               -KERN subtype: userkern, kern: -3.33pt, attr: 4=113 5=30
               -GLUE stretch: +1fil, attr: 4=113 5=30
               HGLYPH subtype: 256, char: C. width: 8.48pt, height: 8.45pt, depth: 0.25pt, attr: 4=113 5=30
               GLYPH subtype: 256, char: 0, width: 9,14pt, height: 8,45pt, depth: 0,25pt, attr: 4=113 5=30
               GLYPH subtype: 256, char: N. width: 8.81pt, height: 8.2pt, attr: 4=113 5=30
               -DISC subtype: regular, penalty: 50, attr: 4=113 5=30
                 Lepre:
                   GLYPH subtype: 256, char: -, width: 3.91pt, height: 2.92pt, attr: 4=113 5=30
               GLYPH subtype: 256, char: T, width: 8.48pt, height: 8.14pt, attr: 4=113 5=30
               GLYPH subtype: 256, char: E, width: 7.99pt, height: 8.17pt, attr: 4=113 5=30
               GLYPH subtype: 256, char: N, width: 8.81pt, height: 8.2pt, attr: 4=113 5=30
               GLYPH subtype: 256, char: T, width: 8.48pt, height: 8.14pt, attr: 4=113 5=30
               -GLYPH subtype: 256, char: S, width: 6.53pt, height: 8.45pt, depth: 0.25pt, attr: 4=113 5=30
               GLYPH char: , width: 3.33pt, attr: 4=113 5=30
               KERN subtype: userkern, kern: -3,33pt, attr: 4=113 5=30
           WHATSIT subtype: pdf colorstack, data: . attr: 4=114 5=27
    GLUE width: 19.87pt, attr: 4=114 5=27
    GLUE subtype: lineskip, attr: 4=114 5=27
    -VLIST height: 592pt, attr: 4=114 5=27
       -WHATSIT subtype: write, stream: 129, data: , attr: 4=114 5=27
       -GLUE subtype: topskip, width: 12pt, attr: 4=114 5=27
       HLIST subtype: box, attr: 4=114 5=27
        GLUE stretch: +1fil, attr: 4=114 5=27
       GLUE attr: 4=114 5=27
   GLUE subtype: baselineskip, width: 30pt, attr: 4=114 5=27
   HLIST subtype: box, width: 390pt, attr: 4=114 5=27
       HHATSIT subtype: pdf colorstack data: 0 0 0 G atts: 4=114 5=27
```



#### ltpdfa.sty

- 1. ltpdfa.sty definiert Optionen, lädt ltdraft.sty und benötigte Pakete, 'ltpdfa.lua'
- 'ltpdfa.init()' lädt und initialisiert das "Backend", alloziert die Attribute
- Befehle aus ltdraft.sty real definieren (meist \directlua), dann sichern, \@restoreLtpdfa sowie \@disableLtpdfa zur Verfügung stellen
- 4. für "Autotagging" angepasste Styles laden (\begin, \end)



"Autotagging"

oder

"Fini"

- Tracking der Umgebungen => /StructElement (typeattr)
- monotone, fortlaufende Nummerierung neuer Elemente (parentattr)

- manuelle Auszeichnung erforderlich
- ansonsten analoger
   Ablauf



### \AtBeginShipoutBox

- Nodeliste traversieren, je nach Knotentyp verschiedene Funktionen (49)
- Content zuordnen u.a.
- Trennstellen und Leerzeichen ermitteln und taggen
- ermitteln der Bounding Boxen (Abb., Tabellen u.a.)
- letztes Element schließen bzw. wieder öffnen

Die Backends ergänzen vor dem Shipout jeweils strukturerzeugende "Anweisungen".



#### \AtEndDocument

- Artefakte und leere /StructElem entfernen
- Verschiebungen von Elementen
- XMP-Metadaten
- /OutputIntent
- /StructTreeRoot mit /RoleMap, /ParentTree usw.



#### **DVI-Output**

- \special toUnicode.pro (Unicodemapping /GlyphNames2Unicode)
- \special dviwriter.pro (Farbprofil, Leerzeichen)
- \special jobname.pro (pdfmark-Anweisungen, erzeugt Elemente)

```
[/Type/StructElem/Subtype/TOCI/_objdef{TOCI62}/At 22/StPNE pdfmar: [/Popped/TOCI62/StPop pdfmark [/Popped/TOC27/StPop pdfmark [/Popped/chapter25/StPop pdfmark
```

• dvips -j0 jobname.dvi => Acrobat Distiller



# Was ist noch zu gewährleisten? Wie?

Die komplette Auszeichnung des Seiteninhaltes ist eine Fleißarbeit und kann gelöst werden durch:

- durch Anpassung vom Makros, welche Inhalt auf der umbrochenen Seite erzeugen (Styles)
- 2. kontextspezifische, manuelle Eingriffe direkt im TFX-Dokument
- 3. Kontrolle mit dem Preflight von Acrobat oder PAC2024
- 4. wieder zu Punkt 1
- 5. ...u.v.m.



### Das Musterbuch

Unter Verwendung des Itpdfa-Paketes wurde beispielhaft ein bei le-tex produziertes Buch angepasst. Die technische Barierefreiheit (-armut) konnte durch Ergänzung im Style sowie direkte Einträge im Quelldokument erreicht werden.

Die DZB (https://dzblesen.de) prüfte das Dokument erfolgreich.


Als mögliche Verbesserung bzw. Kritik wurden nummerierte Überschriftenebenen (/H1, /H2 ...) sowie die schiere Gesamtanzahl der enthaltenen Strukurelemente angemerkt.

Das Musterdokument kann unter

https://www.le-tex.de/de/img/a11y-sample-book.pdf heruntergeladen werden.




### Acrobat X – Reihenfolge






#### Acrobat X – Inhalt






#### Acrobat X – Struktur






### Acrobat X – Report






# PAC2024 - Report





#### PAC2024 – Struktur





# Status – Tagged PDF mit Lua $\LaTeX$ + Dvips

- b die Anpassungen an Styles ist ggf. (mega-)mühsam
- ▶ die verwendeten Fonts spielen noch eine große Rolle
- ► Tabellen sind aufwändig
- korrekte Auszeichnung von Mathe nicht immer eindeutig
- ▶ die Preflight-Prüfung ist aufwändig in Hinblick auf die Automatisierung bzw. Produktion größeren Umfangs

Der Aufwand wäre momentan noch hoch, aber die Produktion relativ einfacher Dokumente vorstellbar.



# Software & Quellen

Die Ausführungen basieren auf:

pdfTEX/TEX-Live 2021

Adobe Acrobat Professional X/DC

PDFMark Reference

PDF Reference

PAC 2024

le-tex Musterbuch

Anregungen, Korrekturen und Fragen gern unter axel.struebing@le-tex.de